

선형대수학팀

3팀
박이현
송지현
유종석
김민서
이주형


행렬식과 역행렬

행렬식 (Determinant)

정사각행렬에 수를 대응시키는 함수로,
 $\det(A)$ 또는 $|A|$ 로 나타냄

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \text{에 대해, 행렬식은}$$

$$\det(A) = ad - bc$$



선형결합으로 변한
 기저벡터들이 이루는
 평행사변형의 넓이

역행렬 (Inverse)

행렬에서 역원의 역할

곱해서 항등원이 나오게 하는 행렬
 A^{-1} 으로 표현하며, 역행렬은 단 **하나**만 존재

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \text{에 대해,}$$

$$A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

노름과 내적

노름 (Norm)

 $p = \text{Norm의 차수}$

$$\|\vec{v}\|_p = L_p = \sqrt[p]{|v_1|^p + |v_2|^p + \dots + |v_n|^p}$$

벡터의 **크기**를 의미, **거리**와 비슷한 개념으로 이해

일반적으로 $p=1$ 인 L1 Norm과 $p=2$ 인 L2 Norm이 자주 사용됨

L1 Norm(맨해튼 노름)

각 벡터들의 **절댓값**을 합한 결과

$$L_1 = |v_1| + |v_2| + \dots + |v_n|$$

L2 Norm(유클리드 노름)

원점에서 벡터에 연결된 직선거리

$$L_2 = \sqrt{|v_1|^2 + |v_2|^2 + \dots + |v_n|^2}$$

내적 (Inner Product)

$$\vec{x} \cdot \vec{y} = x_1y_1 + x_2y_2 + \dots + x_ny_n = |\vec{x}| |\vec{y}| \cos\theta$$

두 벡터의 성분끼리 곱한 후 더한 것, 스칼라값 출력

내적의 기하학적 정의를 통해서 두 벡터 사이의 각도 θ 를 계산 가능

$$\cos(\theta) = \frac{\vec{x} \cdot \vec{y}}{|\vec{x}| |\vec{y}|} \quad \theta = \cos^{-1}\left(\frac{\vec{x} \cdot \vec{y}}{|\vec{x}| |\vec{y}|}\right)$$

직교성과 정사영

직교성 (Orthogonality)


두 벡터가 이루는 각도 θ 가 90° 가 되는 경우 / 두 벡터가 **직교**한다 = 두 벡터의 **내적이 0**이다

$$\cos(90^\circ) = 0 \rightarrow \cos^{-1}(0) = 90^\circ \quad 90^\circ = \cos^{-1}\left(\frac{\vec{x} \cdot \vec{y}}{|\vec{x}||\vec{y}|}\right) \leftarrow \begin{array}{l} \text{앞에서 구한 공식 사용} \\ \theta = \cos^{-1}\left(\frac{\vec{x} \cdot \vec{y}}{|\vec{x}||\vec{y}|}\right) \end{array}$$

$$x \text{ and } y \text{ is } \textit{orthogonal} \rightarrow \vec{x} \cdot \vec{y} = 0$$

정사영 (Orthogonal Projection)

평면 a 밖의 점 P 에서 a 에 그은 수선의 발 P' 를 점 P 의 평면 a 위로의 정사영이라 함
내적의 기하학적 의미 \rightarrow 한 벡터에서 다른 벡터로 정사영 / 두 벡터의 **최소거리**에 위치!



$$y = \hat{y} + z$$

$$y \cdot u = (\hat{y} + z) \cdot u = \hat{y} \cdot u + z \cdot u$$

$$= \hat{y} \cdot u = (au) \cdot u = a(u \cdot u)$$

$$a = \frac{y \cdot u}{u \cdot u}$$

최소제곱법에 적용된 정사영의 원리


두 변수 사이의 관계를 가장 잘 나타내는 직선 추정

회귀분석의 원리

모든 데이터를 통과하는 직선을 구해야 함
= 선형시스템의 해 구하는 것

즉, 선형시스템 $AX=b$ 는

두 열벡터 \vec{a}_1, \vec{a}_2 의 선형결합으로 span한 열공간에 열벡터 \vec{b} 가 존재하는가?



열벡터 \vec{b} 가 열공간 내에 존재하지 않음

열공간으로 최단거리로 직교하여 투영시킴

데이터가 많은 경우

모든 점을 통과하는 직선은 존재하지 않음

선형시스템의 해가 존재하지 않으므로 추정 필요!

해가 존재하지 않는 경우

열공간과 수직으로 내린 벡터는 직교함!

$$A^T \cdot (\vec{b} - A\hat{x}) = 0$$

$$A^T \vec{b} - A^T A \hat{x} = 0$$

$$A^T \vec{b} = A^T A \hat{x}$$

$$\hat{x} = (A^T A)^{-1} A^T \vec{b}$$

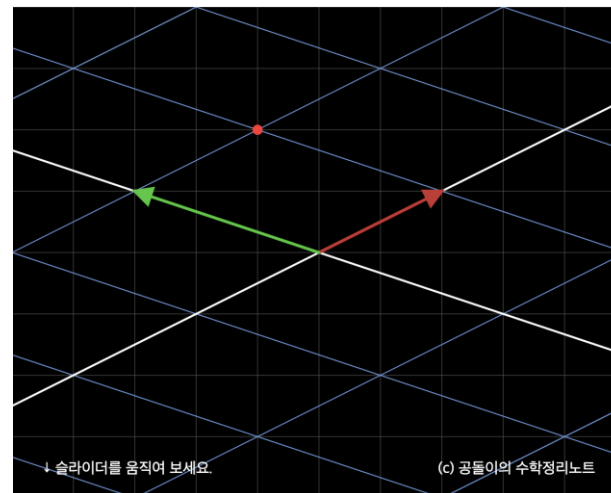

다중선형회귀의 최적화 식과 동일함을 확인 가능

4

고유값과 고유벡터

고유값과 고유벡터

벡터 x 를 행렬 A 를 통해 선형 변환시
기저가 변환되어 새로운 벡터 공간에서 벡터가 변환
→ 대부분의 **벡터는 크기와 방향**이 기존과 달라짐



고유값과 고유벡터

벡터 x 를 행렬 A 를 통해 선형 변환시 기저가 변환되어 새로운 벡터 공간에서 벡터가 변환
 → 대부분의 벡터는 크기와 방향이 기존과 달라짐

하지만, 선형변환 후에도 벡터의 방향은 변하지 않으면서 크기만 변하는 벡터 존재

$\Leftrightarrow Ax = \lambda x$ 를 만족하는 벡터 x 존재

고유값과 고유벡터

벡터 x 와 스칼라 λ , 행렬 A 에 대해 $Ax = \lambda x$ 을 만족하는 경우 해당하는 x 를 고유벡터, λ 를 고유값이라 함

고유벡터 (Eigenvector)

선형변환 시 방향은 유지한 채 길이만 변하는
 영벡터가 아닌 벡터

벡터 x 를 행렬 A 를 통해 선형변환 시
 방향은 유지된 채 길이만 변화

벡터 x 는 고유벡터

고유값 (Eigenvalue)

선형변환시 고유벡터의 길이가 변하는 정도
 고유벡터에 대한 상수배(λ)

벡터 x 를 행렬 A 를 통해 선형변환 시
 λ 배 만큼 고유벡터의 길이가 변화

λ 는 벡터 x 의 고유값

고유벡터 찾기

이항 및 정리
↓

$$Ax = \lambda x \Leftrightarrow (A - \lambda I)x = 0$$

위 방정식의 해를 구하면 고유벡터를 찾을 수 있음

① $(A - \lambda I)$ 의 역행렬이 존재할 경우

② $(A - \lambda I)$ 의 역행렬이 존재하지 않을 경우

양변에 $(A - \lambda I)^{-1}$ 을 곱해주면 해결 가능

$$(A - \lambda I)x = 0 \Leftrightarrow x = 0$$

이 경우,

$x = 0$: trivial solution

그러나,

정의에 의해 영벡터는 고유벡터에서 제외
원하는 형태의 고유벡터를 구할 수 없음

$$\det(A - \lambda I) = 0$$

① $\det(A - \lambda I) = 0$ 를 풀어서 고유값(λ) 구하기

② 구한 고유값(λ)을 $Ax = \lambda x$ 에 대입해 고유벡터(x) 찾기

전치 / 대칭행렬 / 대각행렬

전치 (Transpose)

원래 원소의 행과 열의 위치를 바꾼 행렬 (A^T 으로 표현) $A = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \rightarrow A^T = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$

- ① 전치를 행렬의 곱에 적용하면 곱하는 순서가 변함 $(XYZ)^T = Z^T Y^T X^T$
 ② 역행렬에 전치를 적용시키면 역행렬과 전치의 순서를 바꿀 수 있음 $(A^{-1})^T = (A^T)^{-1}$

대칭행렬 (Symmetric Matrix)

전치를 해도 원래 행렬과 동일한 모습을 보이는 행렬 $A = A^T$ ex) 단위행렬 $I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$

대각행렬 (Diagonal Matrix)

대각성분을 제외한 나머지가 모두 0인 행렬 ex) $A = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 7 & 0 \\ 0 & 0 & 1 \end{bmatrix} \rightarrow \dots A^n = \begin{bmatrix} 3^n & 0 & 0 \\ 0 & 7^n & 0 \\ 0 & 0 & 1^n \end{bmatrix}$

거듭제곱 시 대각성분에만 연산을 하면 되기 때문에 계산 용이

역행렬의 존재성과 선형독립의 관계 / 고유값 분해

선형독립

n 개의 벡터 x_1, x_2, \dots, x_n 에 대한 벡터의 선형결합

$c_1x_1 + c_2x_2 + \dots + c_nx_n = 0$ 에서 상수 c 가 모두 0인 경우를 의미

역행렬의 존재성

A 의 역행렬이 존재한다면 양변에 A^{-1} 을 곱할 수 있음

$\rightarrow c_1 = c_2 = \dots = c_n = 0$ (trivial solution)

따라서, 선형독립인 벡터들을 모아놓은 행렬은 역행렬이 존재!

고유값 분해 (Eigenvalue Decomposition)

$$A = V^{-1} \Lambda V$$

$A : n \times n$ 정방행렬 $V : A$ 의 고유벡터들로만 구성, 역행렬이 존재하는 행렬(선형독립)

$\Lambda : \text{고유값을 대각성분의 원소로 갖는 대각행렬}$

인수분해를 통해 복잡한 방정식을 쉽게 해결하는 것과 유사한 원리

$$(x^2 - 3x + 2)^4 = 0 \text{의 해를 구하기} \quad \rightarrow \quad [(x - 1)(x - 2)]^4 = 0 \text{의 해를 구하기}$$

고유값 분해의 수식적 이해

$$AV = \begin{bmatrix} | & | & & | \\ \lambda_1 v_1 & \lambda_2 v_2 & \dots & \lambda_n v_n \\ | & | & & | \end{bmatrix} = \begin{bmatrix} | & | & & | \\ v_1 & v_2 & \dots & v_n \\ | & | & & | \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} = V\Lambda$$

고유벡터 고유값 대각행렬

Λ : 고유값을 대각성분의 원소로 갖는 대각행렬

$$AV = V\Lambda \quad AVV^{-1} = V\Lambda V^{-1} \quad A = V\Lambda V^{-1}$$

거듭제곱 연산에 적용된 고유값분해

$$A^2 = (V\Lambda V^{-1})(V\Lambda V^{-1}) = V\Lambda V^{-1}V\Lambda V^{-1} = V\Lambda^2 V^{-1}$$

$$A^n = V\Lambda^n V^{-1}$$

대각행렬이기 때문에 거듭제곱 연산이 용이!

$A = V\Lambda V^{-1}$ 의 기하학적 이해

Step 1

V : 축 방향 회전

Step 2

Λ : 길이 변화

Step 3

V^{-1} : 축 방향 회전

대칭행렬의 고유값 분해

대칭행렬에 대해 고유값 분해를 해줄 경우 특수한 상황이 발생

대칭행렬의 고유값 분해

A 가 대칭행렬일 때,

앞과 같이 고유값 분해 진행

$$\begin{aligned} A &= V \Lambda V^{-1} = (V \Lambda V^{-1})^T \\ &= (V^{-1})^T \Lambda^T V^T \\ &= (V^T)^{-1} \Lambda V^T \end{aligned}$$

$$\Lambda = \Lambda^T \quad \Lambda \text{가 대칭행렬이기 때문}$$

역행렬과 전치 순서 교환

$$V^{-1} = V^T \rightarrow V^T V = I \text{ 를 만족}$$

$$V^T V = \begin{bmatrix} - & v_1 & - \\ - & v_2 & - \\ \vdots & \vdots & \vdots \\ - & v_n & - \end{bmatrix} \begin{bmatrix} | & | & & | \\ v_1 & v_2 & \dots & v_n \\ | & | & & | \end{bmatrix} = \begin{bmatrix} v_1^2 & v_1 v_2 & \dots & v_1 v_n \\ v_2 v_1 & v_2^2 & \dots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ v_n \cdot v_1 & \dots & \dots & v_n^2 \end{bmatrix} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & \dots & 1 \end{bmatrix} = I$$

$$\rightarrow v_1 \cdot v_2 = v_1 \cdot v_3 = \dots = 0$$

각 고유벡터의 내적이 모두 0

대칭행렬에서 고유벡터끼리는 모두 서로 직교함! (orthogonal)


특이값 분해

특이값 분해 (Singular Value Decomposition)

일반적인 $m \times n$ 행렬 A 에 대해서 행렬을 분해하는 과정, 고유값 분해의 일반화된 형태

$$A = U\Sigma V^T$$

$A : m \times n$ rectangular matrix $U : m \times m$ orthogonal matrix
 $\Sigma : m \times n$ diagonal matrix $V : n \times n$ orthogonal matrix



직교하는 열벡터(\vec{x}, \vec{y})를 선형변환했을 때,

형태는 변하지만 여전히 직교하는 벡터들($A\vec{x}, A\vec{y}$)을 찾는 것

$$AV = (U\Sigma V^T)V = (U\Sigma)(V^TV) = U\Sigma$$


원래 서로 직교하던 벡터들의 집합 V 에 A 라는 선형변환을 시켜주었지만,

여전히 직교하는 벡터들의 집합 U 에 대해서 Σ 만큼 크기만 변화함

특이값 분해의 기하학적 이해

A 라는 선형변환은 V 를 통해 회전시키고,
크기를 조정해준 후, 다시 회전을 시켜주는 방식

순서대로도 살펴봅시다



$$\begin{array}{c} n \\ \text{---} \\ \boxed{A} \\ \text{---} \\ m \end{array} = \begin{array}{c} m \\ \text{---} \\ \boxed{U} \\ \text{---} \\ m \end{array} \times \begin{array}{c} n \\ \text{---} \\ \boxed{\Sigma} \\ \text{---} \\ n \end{array} \times \begin{array}{c} n \\ \text{---} \\ \boxed{V^T} \\ \text{---} \\ n \end{array}$$

특이값 분해의 활용



고화질 사진에서 저화질 사진으로 축소됨

정보량을 줄여서 데이터를 압축하는 데 쓰임
 기존 사진이 갖고 있는 형태는 유지하면서 (U, V^T)
 데이터 자체의 $\text{scale}(\Sigma)$ 만 줄여주는 것

계속 직교하므로!

$$A = U \Sigma V^T$$