

# 회귀분석팀

6팀

조수미  
김민지  
손재민  
박윤아  
조웅빈



# CONTENTS

1. 다중공선성

2. 변수선택법

3. 정규화

## 다중공선성

### 다중공선성 Multicollinearity

설명변수  $X_j$  간에 서로 **선형적인 상관관계**가 존재  
즉 설명변수가 서로 간의 선형결합으로 표현 가능



설명변수 간 **독립적**이어야 한다는 가정을 위배

회귀의 기본 가정에 관한 내용은 2주차 클린업 내용 참고!

## 다중공선성의 문제점



### 모델의 문제

모델의 검정 결과를 신뢰할 수 없게 됨



전체 회귀식(F-test)은 유의한데  
개별 변수 중 유의한 것이 없는  
말도 안되는 상황 발생 가능

회귀계수들의 분산이 커짐에 따라  $t$ 검정통계량이 작아지기 때문



### 해석의 문제

개별 회귀계수  $\beta$ 에 관한 해석의 어려움 발생



다중공선성이 발생하면  $x_j$ 의 변화가  
다른 설명변수를 변화시키므로  
나머지 변수가 고정된 상황을 가정하기 힘들어짐

회귀계수  $\beta_j$ 는 설명변수  $x_j$ 를 제외한 변수들이 고정되어 있을 때  
 $x_j$ 가 종속변수  $Y$ 에 미치는 영향으로 해석

## 다중공선성 진단 | ③ VIF

VIF 분산팽창인자

$$VIF_j = \frac{1}{1 - R_j^2}, j = 1, \dots, p$$

$$R_j^2 : \mathbf{x}_j = \gamma_1 \mathbf{x}_1 + \dots + \gamma_{j-1} \mathbf{x}_{j-1} + \gamma_{j+1} \mathbf{x}_{j+1} + \dots + \gamma_p \mathbf{x}_p$$

다중선형회귀모델을 적합했을 때의 결정계수

일반적으로  $VIF_j$  값이 10이상인 경우 ( $R_j^2 \geq 0.9$ )

심각한 다중공선성이 존재한다고 판단 가능

## 다중공선성 해결



Variable  
Selection



Normalization



Dimension  
Reduction



Filtering

## 변수선택법

### 변수선택법 variable selection

수 많은 변수들 중 **적절한 변수 조합**을 찾아내는 방법  
서로 상관이 있는 독립변수들을 일부 제거하여 **다중공선성을 해결**



변수선택법을 통해 다중공선성을 완벽하게 제거할 수 없음  
그러나 **최종 모델에 대한 확신**을 얻을 수 있음

## 변수선택지표 | ① Partial F-test

### Partial F-test

비교하는 두 모델이 Nested되어 있을 때만 사용 가능

유의하지 않은 변수들을 없애는 방식으로 변수 선택

Model A

Model B

Nested O  $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$     $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$

Nested X  $y = \beta_0 + \beta_1 x_1 + \beta_4 x_4$     $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$

Model A  $\subset$  Model B 처럼 변수들 집합의 포함관계 성립



## 변수선택지표 | ② 수정결정계수

수정결정계수 *adjusted R-squared*

설명력을 담당하는 결정계수와 변수 개수 패널티가  
수정결정계수를 구하는 식에 들어감



$$R_{adj}^2 = 1 - \frac{SSE / (n - p - 1)}{SST / (n - 1)}$$

## 변수선택지표

$k$ 는 모델의 모수 개수로, 변수 개수에 따른 패널티를 부과한 것

AIC Akaike Information Criterion

$$AIC = -2\log(\text{Likelihood}) + 2k$$

*Likelihood*는 값이 커질수록 모델이 데이터를 잘 설명함

*likelihood*가 커지면 *AIC*는 작아지는데 *AIC*가 낮을수록 더 좋은 모형

BIC Bayesian Information Criterion

$$BIC = -2\log(\text{Likelihood}) + k\log(n)$$

*AIC*와 다르게 데이터의 개수를 모수의 개수에 곱함으로써 *AIC*보다 더 큰 패널티를 부과

*BIC* 역시 낮을수록 더 좋은 모형

## 변수선택법 | ① Best Subset Selection

## Best Subset Selection

가능한 모든 변수들의 조합을 다 고려하는 방법

All Possible Regression

## Best Subset Selection Algorithm

- 1)  $M_1, \dots, M_p$ 개의 모형 적합
- 2) ( $M_1 \sim M_p$ )  $p$ 개의 모형 중  $AIC$  또는  $BIC$ 가 가장 작은 모형 선택
- 3) 만약  $AIC/BIC$ 가 가장 작은 모형이 서로 다를 경우 다른 근거에 의해 선택

$M_k$  ( $k = 1, 2, \dots, p$ )란 변수의 개수를  $k$ 개로 적합했을 때 적합한 회귀식 중  $MSE$ 가 제일 작은 식

## 변수선택법 | ② 전진선택법

## 전진선택법 Forward Selection

Null Model( $y = \beta_0$ )에서 시작해 변수를 하나씩 추가하는 방법

## Forward Selection Algorithm

- 1) Null Model에서 시작해  $X_1$ 부터  $X_p$ 까지의 변수들 중  $AIC$ 와  $BIC$ 를 낮추는 변수를 선택해 추가
- 2) 만약  $X_1$ 이 선택되면  $y = \beta_0 + \beta_1 x_1$ 의 식에서  $X_2$ 부터  $X_p$ 까지의 변수들 중  $AIC$ 와  $BIC$ 를 낮추는 변수 추가
- 3) 위 과정을 반복하며  $AIC$ 와  $BIC$ 가 더 이상 낮아지지 않으면 중단

## 변수선택법 | ③ 후진제거법

후진제거법 Backward Elimination

*Forward selection의 반대*

Full Model ( $y = \beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_px_p$ ) 에서 시작해  
변수를 하나씩 제거하는 방법

## Backward Selection Algorithm

- 1) Full Model에서 시작해  $x_1$ 부터  $x_p$ 까지의 변수 중  
가장  $AIC$ 와  $BIC$ 를 낮추는 변수를 선택해 제거
- 2) 위 과정을 반복하며  $AIC$ 와  $BIC$ 가 더 이상 낮아지지 않으면 중단

## 변수선택법 | ④ 단계적 선택법

### 단계적 선택법 *Stepwise Selection*

Forward Selection과 Backward Elimination 과정을 섞은 방법

### *Stepwise Selection Algorithm*

- 1) Forward selection 과정을 통해 가장 유의한 변수들을 모델에 추가
- 2) 나머지 변수들에 대해 Backward Elimination을 적용
- 3) 제거된 변수는 다시 모형에 포함되지 않으며,  
모형에 유의하지 않은 설명변수가 존재하지 않을 때까지 1)번과 2)번 과정을 반복

## 정규화

### 정규화 Regularization

회귀계수가 가질 수 있는 값에 **제약 조건**을 부여함으로써  
계수들을 작게 만들거나 0으로 만드는 방법



다중공선성은 OLS 추정량의 분산을 크게 증가시킴  
정규화는 OLS 추정량의 **불편성 포기**  
But **분산을 줄이는 효과**가 있음

## Ridge

## Ridge L2 Regularization

SSE를 최소화하면서 회귀계수  $\beta$ 에 제약 조건을 거는 방법

제약 조건식 **L2-norm** 형태  $\rightarrow$  **L2 Regularization**

*L2-norm은 선형대수학 2주차 클린업 참고!*

목적함수

$$\hat{\beta}^{ridge} = \operatorname{argmin}_{\beta} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 \text{ subject to } \sum_{j=1}^p \beta_j^2 \leq s$$

$$\Leftrightarrow \hat{\beta}^{ridge} = \operatorname{argmin}_{\beta} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$




## 목적함수

$$\hat{\beta}^{ridge} = \operatorname{argmin}_{\beta} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 \text{ subject to } \sum_{j=1}^p \beta_j^2 \leq s$$



회귀계수의 최소화

- ① 회귀계수  $\hat{\beta}$ 는 제약조건 원 내부에 존재
- ② SSE를 최소화해야 함



## 목적함수 | 라그랑지안 승수법

regularization term을 통해  
회귀계수 크기 조정

Lagrangian

$$\hat{\beta}^{ridge} = \operatorname{argmin}_{\beta} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

오차제곱합(SSE) 최소화

음수가 아닌 튜닝 파라미터

최적의 모델을 찾는 과정에서 직접 CV를 통해 조정해주는 모수  
제약조건의 크기를 결정 ( $s$ 와는 반대 관계)

# 목적함수 | 라그랑지안 승수법



regularization term을 통해

회귀계수 크기 조정

Lagrangian

[ $\Lambda$ 가 커지는 경우]

$\lambda$ 의 영향력이 증가하므로

$\sum_{j=1}^p \beta_j^2$ 은 작아져야 함

$$\sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2$$

[ $\Lambda$ 가 작아지는 경우]

$\lambda$ 의 영향력이 감소하므로

상대적으로  $\sum_{j=1}^p \beta_j^2$ 의 영향력 커짐

$$\sum_{j=1}^p \beta_j^2$$

오차제곱합(SSE) 최소화

$\therefore$  개별 회귀계수 작아짐 음수가 아닌 튜닝 파라미터: 개별 회귀계수 커짐

$\Lambda \rightarrow \infty$ 이면, 개별 회귀계수  $\approx 0$  이면, OLS 추정량과 동일

제약조건의 크기를 결정 ( $\Lambda$ 와는 반대 관계)

## Lasso

## Lasso L1 Regularization

SSE를 최소화하면서 회귀계수  $\beta$ 에 제약 조건을 거는 방법

제약 조건식 **L1-norm** 형태  $\rightarrow$  **L1 Regularization**

*L1-norm은 선형대수학 1주차 클린업 참고!*

목적함수

$$\hat{\beta}^{Lasso} = \operatorname{argmin}_{\beta} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 \text{ subject to } \sum_{j=1}^p |\beta_j| \leq s$$

$$\Leftrightarrow \hat{\beta}^{Lasso} = \operatorname{argmin}_{\beta} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

## 목적함수

$$\hat{\beta}^{Lasso} = \operatorname{argmin}_{\beta} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 \text{ subject to } \sum_{j=1}^p |\beta_j| \leq s$$




Ridge와 달리

제약 조건의 형태가 마름모꼴

제약조건을 만족시키는

동시에 SSE 최소화

Lasso 제약조건



제약조건 마름모와 SSE 타원과의 접점이 Lasso Estimator

## Elastic-Net

## Elastic-Net

상관성이 있는 변수를 모두 제거하거나 선택하여 성능 보완(Grouping Effect)

변수 간 상관관계가 존재할 때

LASSO의 성능이 떨어지는 한계를 보완하기 위한 방법

목적함수

$$\hat{\beta}^{elastic} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 \quad s. t. \quad \underbrace{t_1 \sum_{j=1}^p |\beta_j|}_{\text{LASSO}} + \underbrace{t_1 \sum_{j=1}^p \beta_j^2}_{\text{RIDGE}} \leq s$$



!! 제약식에 RIDGE의 L2 term과 LASSO의 L1 term이 모두 반영된 모형

## Fused Lasso

## Fused Lasso

변수들 사이의 물리적 거리가 존재한다는  
사전지식을 활용한 모델

목적함수

$$\hat{\beta}^{FL} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n \left( y_i - \beta_0 - \sum_{j=1}^p \beta_j x_i \right)^2 + \lambda_1 \sum_{j=1}^p |\beta_j| + \lambda_2 \sum_{j=1}^p |\beta_j - \beta_{j-1}|$$

LASSO

New  
term



인접한 변수들의 회귀 계수를 비슷하게 추정하도록 만드는 역할